

PS2 - Equipo 03

Catalina Leal Rojas, Lucas Daniel Carrillo Aguirre, Lucas Eduardo Veras
Costa

19 de octubre de 2025

El link del repositorio es: https://github.com/lucaseduardoveras/PS2_Equipo3

1. Introducción

Como uno de los ejercicios fundamentales de la creación de la política pública está la identificación de las características socioeconómicas de los individuos de la sociedad y la naturaleza de ellas. Toda vez que es planeado un proyecto de inversión público o privado, es necesaria la clasificación poblacional con base en las principales características de calidad de vida. Esto, en suma, configura una partición social, entre pobres y no pobres (o bien vulnerables y no vulnerables), que permite al hacedor de política identificar qué factores son más relevantes para los grupos de interés y cuál es, con base en ellos, la manera más efectiva de impactar sus necesidades.

En Colombia, el instrumento de identificación de pobreza más importante es el Sisbén, o Sistema de Identificación de Potenciales Beneficiarios de Programas Sociales, y está administrado por el Departamento Nacional de Planeación, DNP. Este sistema utiliza como insumo encuestas nacionales a hogares y construye una clasificación de cuatro grupos (A a D) a partir de la estimación de su capacidad de generar ingresos y sus características socioeconómicas y demográficas ([Departamento Nacional de Planeación \(DNP\), 2021](#)).

Sin embargo, como todos los instrumentos de medición de la pobreza, el Sisbén ha tenido problemas relacionados con la fiabilidad de sus estimaciones sobre la población vulnerable. Una de las limitaciones de las primeras versiones del instrumento, de hecho, es que los hogares en condiciones relativamente mejores se beneficiaban más de la respuesta estratégica (es decir, la subestimación de sus condiciones materiales) haciendo que la herramienta fuese de cierta forma regresiva ([Bottia et al., 2008](#)). Esto implica que el problema a resolver sea cómo predecir de forma adecuada la pobreza por medio de las herramientas de medición de la pobreza con las que se cuenta actualmente en el ejercicio investigativo y, consecuentemente, cuál es el modelo de clasificación más pertinente para hacerlo.

Para el presente trabajo fue utilizado como insumo el Empalme de las Series de Empleo, Pobreza y Desigualdad - MESE, ([Departamento Administrativo Nacional de Estadística \(DANE\), 2018](#)), que contiene datos desagregados a nivel de individuo y de hogar sobre el nivel de ingreso, el nivel educativo, la afiliación a la seguridad social, las características demográficas de los hogares y el tipo de actividad laboral. Estas variables fueron fundamentales para la construcción de un modelo que pudiera estimar de forma veraz la condición de pobreza, especialmente porque presentan información complementaria a la expuesta por el Sisbén, y porque cuenta con un respaldo metodológico robusto por cuenta del DANE.

En cuanto a los modelos de clasificación, siete fueron aplicados a las bases de datos expuestas: Regresión Lineal, Regresión Logística (Logit), Elastic Net, CART, Random Forest, Gradient Boosting y Naive Bayes. De ellos, aquellos que tuvieron el mejor rendimiento en la competencia propuesta en Kaggle, fueron los dos planteados con Random Forest, con un puntaje de 0.63 cada uno. El primero de ellos se formuló utilizando la medida de F1

como principal métrica de desempeño, y el segundo se hizo utilizando 'bagging'. Además, las variables importantes en ambos modelos fueron las características demográficas del hogar, características de inserción laboral y el tipo de vivienda.

Este resultado sugiere tres nociones fundamentales: (i) el problema planteado parece tener patrones no lineales entre las variables, factor que implica la necesidad de utilizar modelos de entrenamiento que aprenden iterativamente como los árboles, (ii) el bagging reduce la varianza sin incrementar en mayor medida el sesgo, lo que es útil cuando las unidades muestrales son heterogéneas, como en este caso los hogares, (iii) el uso de una cantidad significativamente mayor de árboles (1,000) fue importante para capturar una profundidad suficiente en la complejidad de los datos.

2. Datos

Los datos empleados en este análisis provienen del DANE y de la misión para el “Empalme de las Series de Empleo, Pobreza y Desigualdad - MESE”. En el repositorio *Kaggle* se encuentran cuatro conjuntos de datos divididos en muestras de entrenamiento y de prueba, tanto a nivel de hogar como individual. En ambos casos, las bases pueden vincularse mediante la variable *id*.

Dado que la versión básica de *GitHub* no permite trabajar simultáneamente con los cuatro archivos —debido a que su tamaño supera los 45 MB—, cada integrante del equipo descargó los datos en su computadora local. Varias de las variables del conjunto de prueba conservan los mismos códigos utilizados en la encuesta original del DANE. Por esta razón, se consultó el diccionario de la encuesta y se modificaron los nombres de las variables con el fin de hacerlos más interpretables y facilitar el proceso de análisis.

Las variables incluidas en el conjunto de entrenamiento no coinciden completamente con las del conjunto de prueba. Dado que solo pueden emplearse como predictores las variables presentes en este último, se eliminaron del conjunto de entrenamiento aquellas no disponibles en la base de prueba. Así, como la creación y selección de variables no responde a una receta única, en esta etapa se adoptó un enfoque basado en la intuición analítica y el criterio del equipo, priorizando la relevancia teórica y empírica de cada indicador.

Respecto a los datos individuales, se decidió excluir las variables relacionadas con ingresos debido a la alta proporción de valores faltantes. Por ejemplo, la variable que reporta el ingreso neto mensual carece de información para aproximadamente el 80 % de los individuos. En cambio, se consideró pertinente incluir variables de ocupación. Para cada hogar se calculó la proporción de personas ocupadas respecto al total de miembros, bajo la hipótesis de que una mayor participación laboral reduce la probabilidad de pobreza. De manera análoga, se estimó la proporción de personas inactivas, partiendo del supues-

to de que una mayor inactividad dentro del hogar incrementa su vulnerabilidad económica.

En cuanto a las características socioeconómicas, se construyeron diversas variables a nivel de hogar. Se incluyó una variable dicotómica que identifica si el jefe o la jefa del hogar es mujer, con el objetivo de capturar posibles diferencias estructurales asociadas al género en la incidencia de la pobreza. Asimismo, se calcularon indicadores demográficos como la proporción de menores de edad y la tasa de dependencia, definida como la relación entre el número de personas menores y mayores de edad respecto a la población en edad de trabajar. Se espera que una mayor proporción de dependientes afecte negativamente la capacidad económica del hogar.

También se construyó una variable que mide la proporción de personas con educación superior dentro del hogar, así como el nivel educativo máximo alcanzado por sus miembros. Estas medidas buscan captar el efecto positivo del capital humano sobre la generación de ingresos y la movilidad socioeconómica.

Además, se elaboraron indicadores laborales agregados, entre ellos la tasa de ocupación y la tasa de inactividad del hogar, calculadas como la proporción de personas ocupadas o inactivas sobre la población en edad de trabajar. Se anticipa que una mayor tasa de ocupación se asocie con una menor probabilidad de pobreza, mientras que una alta tasa de inactividad la incremente.

Se incluyeron, asimismo, variables que reflejan la estructura de propiedad y la intensidad laboral del hogar. Destacan la proporción de personas con trabajo propio —como aproximación al autoempleo o emprendimiento informal— y el número total de horas trabajadas durante la semana de referencia. Estos indicadores permiten aproximar la disponibilidad de recursos laborales y la resiliencia del hogar frente a choques económicos.

Finalmente, se construyó un conjunto de variables específicas para el jefe o la jefa del hogar, con el propósito de capturar sus características individuales y su influencia directa sobre la situación económica familiar. Entre ellas se consideraron el género, la edad y el nivel educativo alcanzado, entendidos como factores determinantes del potencial de generación de ingresos. Asimismo, se incluyeron indicadores laborales que identifican si el jefe o la jefa del hogar se encuentra ocupado(a), las horas trabajadas durante la semana de referencia, su afiliación al sistema de seguridad social —como medida de formalidad laboral— y la condición de trabajo propio o negocio familiar. Estas variables permiten evaluar el grado de estabilidad económica y las estrategias de inserción laboral adoptadas por los hogares.

En cuanto a las variables disponibles a nivel de hogar, se consolidó un conjunto de indicadores que permite capturar las condiciones habitacionales y estructurales del entorno doméstico, complementando la información demográfica y laboral previamente agregada desde la base individual.

En primer lugar, se incorporó la variable *número de habitaciones*, que permite aproximar el tamaño y la capacidad física de la vivienda. Este indicador es relevante, ya que un menor número de habitaciones por hogar suele asociarse con condiciones de hacinamiento, las cuales representan un componente clave del bienestar material y un reflejo de carencias estructurales.

Asimismo, se incluyó la variable *tipo de vivienda*, que distingue entre viviendas propias, arrendadas, en usufructo u ocupadas sin título. Esta variable captura el grado de seguridad en la tenencia y constituye un indicador indirecto de la estabilidad económica y patrimonial del hogar. Se espera que los hogares con vivienda propia —especialmente aquellos que la han adquirido totalmente— presenten menor probabilidad de pobreza en comparación con los hogares en arriendo o en posesión informal.

También se consideró la variable *número de personas por hogar*, que actúa como un control demográfico básico y refleja la carga familiar total. Hogares más numerosos tienden a enfrentar mayores presiones sobre los recursos disponibles, especialmente cuando el número de dependientes es elevado. Además, se mantuvo la variable *Dominio*, que identifica el dominio geográfico de la encuesta y permite capturar diferencias territoriales y regionales en las condiciones socioeconómicas. Su inclusión es relevante, dado que las dinámicas del mercado laboral, los niveles de precios y la disponibilidad de infraestructura difieren sustancialmente entre las regiones del país.

En el total usamos 27 variables para hacer nuestras predicciones. En conjunto, estas variables —de carácter habitacional, demográfico y geográfico— complementan las dimensiones laborales y educativas incluidas en las bases individuales y aportan información relevante sobre los determinantes estructurales de la pobreza a nivel de hogar. Su inclusión en el modelo busca capturar tanto las restricciones de capital físico como las condiciones del entorno residencial, las cuales inciden directamente en el bienestar y la vulnerabilidad económica de los hogares. De este modo, se espera mejorar la capacidad predictiva del modelo al aplicar los datos de prueba.

Pasando al análisis de los datos empleados, es importante considerar el desbalance de clases presente en el conjunto de entrenamiento. Aproximadamente el 80 % de los hogares son no pobres en el conjunto de datos de muestreo, un aspecto que será examinado con mayor detalle en la sección siguiente. El conjunto de hogares en el conjunto de datos de entrenamiento posee 164959 observaciones mientras que el conjunto de datos de prueba posee 66168 observaciones, al rededor de 40 % del tamaño del conjunto de prueba.

El Cuadro 1 presenta las estadísticas descriptivas (media, mediana y desviación estándar) para los hogares pobres y no pobres en el conjunto de entrenamiento. Tal como se anticipa teóricamente, las características asociadas a la informalidad y la precariedad laboral son más pronunciadas entre los hogares pobres. Estos registran mayores tasas de inactividad y de trabajo por cuenta propia, así como menores horas trabajadas, tanto en total como

por parte del jefe o jefa del hogar, y un menor número de personas ocupadas.

En el plano socioeconómico y demográfico, los hogares pobres presentan en promedio más integrantes, mayor número de menores de edad, y jefes de hogar más jóvenes, lo que refleja una mayor carga de dependencia y menor acumulación de capital humano. En contraste, los hogares no pobres exhiben niveles educativos más altos, una mayor proporción de miembros con educación superior y tasas de ocupación más elevadas, factores coherentes con una menor vulnerabilidad económica.

El Cuadro 1 presenta las medias de las variables categóricas empleadas en las predicciones. Se observa que la proporción de hogares encabezados por mujeres es superior entre los hogares pobres, lo que sugiere posibles desigualdades de género en el acceso a recursos económicos. Asimismo, la proporción de jefes de hogar ocupados es significativamente mayor entre los hogares no pobres, lo que refleja la estrecha relación entre inserción laboral y condiciones de vida.

En cuanto a las condiciones habitacionales, se evidencia que las familias no pobres residen en mayor proporción en viviendas propias y totalmente pagadas, mientras que los hogares pobres presentan una concentración más alta en viviendas en arriendo o en condiciones de tenencia precaria, como la posesión sin título.

Finalmente, respecto al nivel educativo, tanto del jefe del hogar como del conjunto de sus miembros, se aprecia un patrón claro: los hogares no pobres exhiben una proporción considerablemente mayor de educación universitaria, mientras que los hogares pobres se concentran en niveles educativos básicos, especialmente primaria y media. Este contraste refuerza la hipótesis de que el capital humano constituye un determinante fundamental de la pobreza en el país.

Llevando en cuenta el porcesamiento de los datos, la próxima sección describe los modelos usados para hacer las predicciones.

3. Modelos y Resultados

En esta sección describimos los modelos utilizados para las predicciones y el modelo que alcanzó el mejor desempeño. Las estimaciones se realizaron empleando los siguientes algoritmos de clasificación: **Regresión Logit**, **Naive Bayes**, **Random Forest**, **CART**, **Elastic Net** y **Boosting**.

Para cada modelo, con excepción de la Regresión Logit, se calibraron los *hiperparámetros* mediante *validación cruzada de cinco pliegues* (*five-fold cross-validation*). Dado que la métrica utilizada para evaluar las predicciones en la competencia es la **estadística F**,

optamos por emplearla también como criterio de desempeño durante la calibración.

La **estadística F**, o *F1-score*, se define como la media armónica entre la *precisión* (*precision*) y la *sensibilidad* (*recall*), cuya fórmula es la siguiente:

$$F_1 = 2 \cdot \frac{\text{Precisión} \cdot \text{Sensibilidad}}{\text{Precisión} + \text{Sensibilidad}} \quad (1)$$

donde:

$$\text{Precisión} = \frac{TP}{TP + FP}, \quad \text{Sensibilidad} = \frac{TP}{TP + FN} \quad (2)$$

y *TP*, *FP* y *FN* representan, respectivamente, los verdaderos positivos, falsos positivos y falsos negativos.

Cabe señalar que los datos de entrenamiento presentan un **fuerte desbalance de clases**, lo cual tiende a sesgar los modelos hacia la clase más frecuente, afectando negativamente la predicción de la clase minoritaria —en este caso, los hogares pobres. Para mitigar este problema, aplicamos *técnicas de remuestreo* (tanto *oversampling* como *undersampling*) en cada modelo.

Adicionalmente, el **umbral de corte** en la probabilidad estimada p , que usualmente se fija en 0.5 por convención, fue **recalibrado** para maximizar la métrica F_1 en cada modelo.

3.1. Selección del Modelo y Entrenamiento

3.2. Calibración de los Hiperparámetros

3.3. Análisis Comparativa

4. Conclusiones

5. Anexos

Cuadro 1. Estadísticas descriptivas para las variables numéricas

Variable	Media		Mediana		Desv. Est.	
	Pobre	No Pobre	Pobre	No Pobre	Pobre	No Pobre
N. de Personas	4.13	3.08	4.00	3.00	2.03	1.64
N. de Habitaciones	3.03	3.48	3.00	3.00	1.13	1.25
Edad del Jefe	46.77	50.32	45.00	50.00	16.24	16.35
H. Trab. del Jefe	28.62	34.49	32.00	42.00	25.23	24.67
N. Mujeres	2.24	1.62	2.00	1.00	1.35	1.10
N. Menores	1.55	0.62	1.00	0.00	1.34	0.86
N. Mayores	0.27	0.33	0.00	0.00	0.57	0.61
N. Educ. Sup.	0.36	0.88	0.00	1.00	0.69	1.00
N. Cuenta Propia	0.86	0.65	1.00	0.00	0.85	0.80
Horas Trab. Total	52.46	71.11	48.00	60.00	43.68	49.59
N. Ocupados	1.26	1.57	1.00	1.00	0.99	1.03
N. Pet	3.02	2.64	3.00	2.00	1.53	1.35
N. Inactivos	1.45	0.92	1.00	1.00	1.17	0.96
Tasa Ocup.	0.43	0.62	0.50	0.67	0.31	0.34
Tasa Inac.	0.46	0.33	0.50	0.33	0.31	0.33
Tasa Educ. Sup.	0.13	0.35	0.00	0.25	0.25	0.38
Tasa Dependencia	67.42	37.84	60.00	33.33	52.86	39.45
Tasa Cuenta Propia	0.30	0.26	0.25	0.00	0.29	0.33

Cuadro 2. Promedios de variables categóricas por condición de pobreza

Variable	Pobre	No Pobre
Jefe del Hogar Mujer	0.468	0.406
Jefe del Hogar Ocupado	0.643	0.727
Jefe del Hogar Cuenta Propia	0.473	0.322
<i>Tipo de vivienda</i>		
Propia Totalmente Pagada	0.275	0.403
Propia la Están Pagando	0.017	0.038
En arriendo o subarriendo	0.438	0.379
En usufructo	0.158	0.149
posesión sin título	0.111	0.030
<i>Nivel educativo del jefe del hogar</i>		
Preescolas	0.0002	0.00003
Primaria	0.378	0.259
Medias	0.253	0.263
Secundaria	0.162	0.124
Universitaria	0.103	0.315
<i>Máximo nivel educativo del hogar</i>		
Preescolar	0.001	0.0001
Primaria	0.128	0.093
Media	0.385	0.264
Secundaria	0.201	0.087
Universitaria	0.261	0.544

Referencias

- Bottia, M., Cardona, L., and Medina, C. (2008). Bondades y limitaciones de la focalización con proxy means tests: El caso del sisben en colombia. Accedido en octubre de 2025.
- Departamento Administrativo Nacional de Estadística (DANE) (2018). Medición de pobreza monetaria y desigualdad 2018. <https://microdatos.dane.gov.co/index.php/catalog/608>. Accedido en octubre de 2025.
- Departamento Nacional de Planeación (DNP) (2021). ¿qué es el sisbén? <https://www.sisben.gov.co/Paginas/que-es-sisben.html>. Accedido en octubre de 2025.