

# Datos

Catalina Leal Rojas, Lucas Daniel Carrillo Aguirre, Lucas Eduardo  
Veras Costa

October 20, 2025

Los datos utilizados provienen de la *Medición de Pobreza Monetaria y Desigualdad 2018*, elaborada por el DANE en el marco de la misión *Empalme de las Series de Empleo, Pobreza y Desigualdad (MESE)*.

Esta fuente permite analizar con detalle las condiciones demográficas, laborales, educativas y de vivienda de los hogares colombianos.

Los datos se obtuvieron de la plataforma *Kaggle*, donde se desarrolla una competencia para predecir la pobreza de los hogares.

El conjunto se estructura en cuatro archivos: a nivel de hogar e individual, divididos en muestras de *training* y *testing*.

# Procesamiento y selección de variables

- Se integraron las bases de hogares y personas mediante el identificador id.
- Se eliminaron variables con más del 40% de valores faltantes.
- Las variables restantes se seleccionaron según su relevancia teórica y empírica.
- Las variables de ingreso del conjunto de entrenamiento no se incluyeron, al no estar disponibles en el conjunto de prueba.

**En total:** 26 variables —numéricas, categóricas y binarias— agrupadas en dimensiones laborales, demográficas, educativas y de vivienda.

**Table:** Descripción y tipo de las variables utilizadas

| Variable       | Tipo       | Descripción                               |
|----------------|------------|-------------------------------------------|
| Dominio        | Categórica | Área metropolitana o zona rural           |
| Pobre          | Binaria    | 1 si el hogar es pobre, 0 de lo contrario |
| Nper           | Numérica   | Número de personas en el hogar            |
| n_habitaciones | Numérica   | Número de habitaciones                    |
| tipo_vivienda  | Categórica | Tipo de vivienda                          |
| bin_headWoman  | Binaria    | 1 si el jefe del hogar es mujer           |
| cat_educHead   | Categórica | Nivel educativo del jefe del hogar        |
| t_ocu          | Numérica   | Tasa de ocupación                         |
| t_inac         | Numérica   | Tasa de inactividad                       |
| t_dependencia  | Numérica   | Proporción de dependientes en el hogar    |

# Estadísticas descriptivas (I)

- El conjunto de entrenamiento tiene 164.959 hogares y el de prueba 66.168 ( $\approx 40\%$  de lo de entrenamiento).
- Existe un fuerte desbalance: 80% de hogares no pobres.

**Table:** Diferencia de medias entre hogares pobres y no pobres (extracto)

| Variable              | Pobre | No Pobre | Dif.  | Signif. |
|-----------------------|-------|----------|-------|---------|
| N. de Personas        | 4.13  | 3.08     | +1.05 | ***     |
| N. Habitaciones       | 3.03  | 3.48     | -0.45 | ***     |
| Edad Jefe             | 46.8  | 50.3     | -3.5  | ***     |
| Horas Trabajadas Jefe | 28.6  | 34.5     | -5.9  | ***     |
| Tasa Ocupación        | 0.43  | 0.62     | -0.19 | ***     |
| Tasa Inactividad      | 0.46  | 0.33     | +0.13 | ***     |

# Estadísticas descriptivas (II)

Los hogares pobres presentan:

- Más integrantes y mayor número de menores de edad.
- Menor nivel educativo y menor proporción con educación superior.
- Mayores tasas de inactividad y trabajo por cuenta propia.

**Table:** Promedios de variables categóricas

| <b>Variable</b>       | <b>Pobre</b> | <b>No Pobre</b> |
|-----------------------|--------------|-----------------|
| Jefe mujer            | 0.47         | 0.41            |
| Jefe ocupado          | 0.64         | 0.73            |
| Jefe cuenta propia    | 0.47         | 0.32            |
| Vivienda propia total | 0.28         | 0.40            |
| Arriendo              | 0.44         | 0.38            |
| Sin título            | 0.11         | 0.03            |
| Universitaria (jefe)  | 0.10         | 0.32            |

# Conclusiones descriptivas

- Los hogares pobres exhiben condiciones laborales más precarias, menor capital humano y mayor dependencia económica.
- Las diferencias en educación y tenencia de vivienda son las más marcadas entre grupos.
- Estas variables reflejan desigualdades estructurales que el modelo buscará capturar para predecir la pobreza.

**Implicación:** las dimensiones laborales, educativas y habitacionales son determinantes esenciales en la clasificación de pobreza.