

Sección 1: Datos

Catalina Leal Rojas, Lucas Daniel Carrillo Aguirre,
Lucas Eduardo Veras Costa

- Los datos provienen de la *Medición de Pobreza Monetaria y Desigualdad 2018*, elaborada por el *Departamento Administrativo Nacional de Estadística (DANE)* en el marco de la misión *Empalme de las Series de Empleo, Pobreza y Desigualdad (MESE)*.
- Esta iniciativa busca unificar y armonizar las series de empleo, pobreza y desigualdad en Colombia, fortaleciendo la consistencia de los indicadores sociales.
- La fuente contiene información detallada sobre ingresos, educación, ocupación, vivienda y composición familiar, tanto a nivel individual como de hogar.
- Los datos se obtuvieron de la plataforma *Kaggle*, donde se desarrolla una competencia para predecir la condición de pobreza.

Procesamiento y limpieza de datos

- Se integraron las bases de hogares y personas mediante el identificador único id.
- Se excluyeron las variables con más del 40% de valores faltantes, evitando imputaciones poco confiables.
- La selección final se basó en criterios teóricos y empíricos sobre los determinantes de la pobreza.
- Las variables de ingreso del conjunto de entrenamiento no se incluyeron, ya que no estaban disponibles en el conjunto de prueba.

Tamaño muestral:

164.959 hogares en el conjunto de entrenamiento y 66.168 en el de prueba (40% del primero).

Variables derivadas del nivel individual

- Las variables provenientes de la base de personas corresponden a:
 - Sumas o proporciones de individuos que cumplen determinada condición (ocupados, inactivos, con educación superior, etc.).
 - Características del jefe o jefa del hogar (sexo, edad, ocupación, condición laboral).
- Estas medidas permiten aproximar la **estructura demográfica**, el **capital humano** y la **inserción laboral** del hogar.

Variables del mercado laboral

- Se construyeron las tasas de **ocupación** e **inactividad**, definidas como:

$$t_{ocu} = \frac{\text{Ocupados}}{\text{Personas en edad de trabajar}}, \quad t_{inac} = \frac{\text{Inactivos}}{\text{Personas en edad de trabajar}}$$

- Hipótesis: mayor participación laboral $\Rightarrow$ menor probabilidad de pobreza.
- Otras variables laborales incluidas:
 - Horas totales trabajadas por los miembros del hogar.
 - Número de trabajadores por cuenta propia.
 - Dicotómica: jefe(a) de hogar cuenta propia.
- Estas variables reflejan la **resiliencia económica** del hogar ante choques del mercado laboral.

Características socioeconómicas y demográficas

- Variables demográficas y de género:
 - Número de mujeres.
 - Jefe(a) de hogar mujer (binaria).
 - Tasa de dependencia:

$$t_{dep} = \frac{\text{Población } \leq 15 \text{ o } \geq 65}{\text{Población en edad de trabajar}}$$

- Variables educativas:
 - Proporción de personas con educación superior.
 - Nivel educativo máximo alcanzado en el hogar.
- Estas medidas capturan el **capital humano** y su efecto sobre los ingresos y la movilidad social.

Condiciones habitacionales y geográficas

- Variables de vivienda:
 - Número de habitaciones.
 - Tipo de vivienda (propia, arrendada, usufructo, ocupada sin título).
- Variable demográfica de control:
 - Número total de personas en el hogar.
- Variable geográfica:
 - Dominio (área metropolitana o rural).
- Estas variables complementan las dimensiones laboral y educativa, reflejando el **bienestar material** y las **condiciones estructurales del hogar**.

Estadísticas descriptivas para las variables numéricas

Variable	Media		Mediana		Desv. Est.	
	Pob.	No Pob.	Pob.	No Pob.	Pob.	No Pob.
N. Personas	4.13	3.08	4.00	3.00	2.03	1.64
N. Habitaciones	3.03	3.48	3.00	3.00	1.13	1.25
Edad Jefe	46.77	50.32	45.00	50.00	16.24	16.35
H. Trab. Jefe	28.62	34.49	32.00	42.00	25.23	24.67
N. Mujeres	2.24	1.62	2.00	1.00	1.35	1.10
N. Menores	1.55	0.62	1.00	0.00	1.34	0.86
N. Mayores	0.27	0.33	0.00	0.00	0.57	0.61
N. Educ. Sup.	0.36	0.88	0.00	1.00	0.69	1.00
N. Cta. Propia	0.86	0.65	1.00	0.00	0.85	0.80
Horas Trab. Tot.	52.46	71.11	48.00	60.00	43.68	49.59
N. Ocupados	1.26	1.57	1.00	1.00	0.99	1.03
N. PET	3.02	2.64	3.00	2.00	1.53	1.35
N. Inactivos	1.45	0.92	1.00	1.00	1.17	0.96
Tasa Ocup.	0.43	0.62	0.50	0.67	0.31	0.34
Tasa Inac.	0.46	0.33	0.50	0.33	0.31	0.33
Tasa Educ. Sup.	0.13	0.35	0.00	0.25	0.25	0.38
Tasa Dependencia	67.42	37.84	60.00	33.33	52.86	39.45
Tasa Cta. Propia	0.30	0.26	0.25	0.00	0.29	0.33

Table 1: Promedios de variables categóricas por condición de pobreza

Variable	Pobre	No Pobre
Jefe del Hogar Mujer	0.468	0.406
Jefe del Hogar Ocupado	0.643	0.727
Jefe del Hogar Cuenta Propia	0.473	0.322
<i>Tipo de vivienda</i>		
Propia Totalmente Pagada	0.275	0.403
Propia la Están Pagando	0.017	0.038
En arriendo o subarriendo	0.438	0.379
En usufructo	0.158	0.149
posesión sin título	0.111	0.030
<i>Nivel educativo del jefe del hogar</i>		
Preescolas	0.0002	0.00003
Primaria	0.378	0.259
Medias	0.253	0.263
Secundaria	0.162	0.124
Universitaria	0.103	0.315
<i>Máximo nivel educativo del hogar</i>		
Preescolar	0.001	0.0001
Primaria	0.128	0.093
Media	0.385	0.264
Secundaria	0.201	0.087
Universitaria	0.261	0.544

Conclusiones descriptivas

- Los hogares pobres presentan mayor número de integrantes, más menores y mayores tasas de inactividad.
- Exhiben menor nivel educativo y mayor proporción de trabajo por cuenta propia.
- Los hogares no pobres muestran una inserción laboral más estable y mejores condiciones de vivienda.
- Estas diferencias confirman la coherencia teórica de las variables incluidas en el modelo predictivo.